



1.如何表示一个单词的含义?

含义的定义:

- the idea that is represented by a word, phrase,
- the idea that a person wants to express by using words, signs, etc.
- the idea that is expressed in a work of writing, art, etc.

signifier (symbol) \Leftrightarrow signified (idea or thing)

= denotational semantics

独热编码

维度大小为整个语料库，对应单词在自己位置上为1，其余位置为0，所以称为独热编码

缺点

不同的单词向量之间相互正交，无法计算相似度

2.分布式语义

一个单词的含义通过邻近单词来定义

通过出现在类似上下文中的相同位置来判断不同词之间的相似度

词向量

以下等义

- word vectors
- word embeddings
- word representations

3.Word2vec:Overview

word2vec:一种学习词向量的模型框架

理念

- 我们有大量的文本语料
- 待修正的词表中的每一个单词都通过一个向量来表示
- 对于文本中的每一个位置t，都有一个中心单词C和指定大小的上下文O

- 对于C和O，通过每个词向量的相似度来计算给定C情况下O出现的概率(skip-gram)和相反的情况(CBOW)
- 不断地修正词向量使得概率最大化

目标函数：object function

For each position $t = 1, \dots, T$, predict context words within a window of fixed size m , given center word w_j .

$$\text{Likelihood} = L(\theta) = \prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} P(w_{t+j} | w_t; \theta)$$

θ is all variables to be optimized

sometimes called *cost* or *loss* function

The **objective function** $J(\theta)$ is the (average) negative log likelihood:

$$J(\theta) = -\frac{1}{T} \log L(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

Minimizing objective function \Leftrightarrow Maximizing predictive accuracy

- 使目标函数最小化：

$$J(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w_{t+j} | w_t; \theta)$$

- 计算条件概率
- 用两个向量来表示两个单词
 - v_w ：当单词是中心单词时
 - u_w ：当单词属于上下文时
- 对于一个中心单词C和一个上下文单词o求条件概率时：

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

- 分子：点积比较o和c的相似性

- 分母：对整个词汇进行归一化以给出概率分布
- **softmax**: 对任意分布值求概率

$$\text{softmax}(x_i) = \frac{\exp(x_i)}{\sum_{j=1}^n \exp(x_j)} = p_i$$

训练模型：通过损失函数来优化参数

计算所有的向量梯度

- theta：代表所有的模型参数
- 小技巧：

$$\frac{\partial \mathbf{x}^T \mathbf{a}}{\partial \mathbf{x}} = \frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

$$\max_{\theta} J'(\theta) = \prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} p(w'_{t+j} | w_t; \theta)$$

目标函数最小化

$$J(\theta) = -\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log p(w'_{t+j} | w_t)$$

$$p(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w=1}^V \exp(u_w^T v_c)}$$

$$\frac{\partial}{\partial v_c} \log \frac{\exp(u_0^T v_c)}{\sum_{w=1}^V \exp(u_w^T v_c)}$$

$$\frac{\partial}{\partial v_c} \log \exp(u_0^T v_c) - \frac{\partial}{\partial v_c} \log \sum_{w=1}^V \exp(u_w^T v_c)$$

numerator denominator

$$\frac{\partial}{\partial v_c} \log \exp(u_0^T v_c) = u_0$$

$$\frac{\partial}{\partial v_c} \log \sum_w^{\textcircled{1}} \exp(u_w^T v_c)$$

→ 语料库

$$= \frac{\frac{\partial}{\partial v_c} \sum_w^T \exp(u_w^T v_c)}{\sum_w^T \exp(u_w^T v_c)} = \frac{\sum_w^T u_w \exp(u_w^T v_c)}{\sum_w^T \exp(u_w^T v_c)}$$

$$\frac{\partial}{\partial v_c} \log p(x|c) = u_0 - \sum_{x=1}^V \left(\frac{\exp(u_x^T v_c)}{\sum_{w=1}^V \exp(u_w^T v_c)} \right) \cdot u_x$$

$p(x|c)$

$$= u_0 - \sum_{x \in V} p(x|c) \cdot u_x$$